CredScore AI: Decifrando o Risco de Crédito com Aprendizado de Máquina Explicável e Avaliação de Equidade

Rodrigo Daiske Uehara (RA 10440295)[1]

[1]Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
São Paulo, SP – Brasil

10440295@mackenzista.com.br, daiskeuehara20@hotmail.com

Abstract. *This paper compares Logistic Regression, Random Forest and XGBoost for predicting consumer credit default on the public German Credit dataset (1,000 applicants). The protocol uses repeated stratified cross-validation with class weighting or SMOTENC inside training folds, a threshold set by the dataset's 5:1 cost matrix, Platt calibration, SHAP explanations and group fairness metrics with bootstrap confidence intervals. All models beat trivial baselines, but differences among them were within sampling uncertainty: the selected Random Forest reached a test PR-AUC of 0.564 and recall of 0.86, while Logistic Regression performed as well or better. No relevant error-rate gap was found between sexes, but good payers aged 25 or less were wrongly rejected more often (ΔFPR = +0.16; 95% CI +0.06 to +0.26), even without sensitive attributes.*

Resumo. *Este artigo compara Regressão Logística, Random Forest e XGBoost na previsão de inadimplência em crédito ao consumidor, com a base pública German Credit (1.000 solicitantes). O protocolo usa validação cruzada estratificada repetida, peso de classe ou SMOTENC dentro das partições de treino, limiar definido pela matriz de custo 5:1 da base, calibração de Platt, explicações SHAP e métricas de equidade entre grupos com intervalos de confiança por bootstrap. Todos os modelos superaram as referências triviais, mas as diferenças entre eles ficaram dentro da incerteza amostral: o Random Forest selecionado obteve PR-AUC de 0,564 e recall de 0,86 no teste, e a Regressão Logística teve desempenho igual ou superior. Não houve diferença relevante de erro entre sexos, mas bons pagadores de até 25 anos foram negados indevidamente com mais frequência (ΔFPR = +0,16; IC 95%: +0,06 a +0,26), mesmo sem os atributos sensíveis.*

1. Introdução

1.1. Contextualização

A concessão de crédito é uma atividade central das instituições financeiras e envolve dois tipos de erro com consequências distintas. Conceder crédito a um cliente que não honrará o pagamento gera inadimplência e prejuízo; negar crédito a um cliente que pagaria corretamente gera perda de receita para a instituição e exclusão para o cliente. Essas decisões são apoiadas por modelos de *credit scoring*, tradicionalmente estatísticos, e o avanço do aprendizado de máquina permite capturar relações não lineares entre os atributos dos solicitantes.

Este trabalho trata de **crédito ao consumidor para pessoas físicas**. O público-alvo são os solicitantes de crédito de um banco alemão cuja identidade não é divulgada, representados no conjunto de dados público Statlog (German Credit Data) [Hofmann

1994], com 1.000 clientes. Nessa base, a inadimplência corresponde ao rótulo "mau pagador" atribuído pela própria instituição; a documentação não informa o horizonte de atraso que define esse rótulo. Assume-se, portanto, o rótulo tal como fornecido, limitação discutida na Seção 4.1. Em um cenário com dados próprios, recomenda-se definir o evento explicitamente, por exemplo, atraso superior a 90 dias nos 12 meses seguintes à concessão.

1.2. Justificativa

A tarefa possui variável-alvo rotulada e dados públicos disponíveis, o que justifica o aprendizado supervisionado. A comparação entre um modelo simples e interpretável (Regressão Logística) e modelos de maior capacidade (Random Forest e XGBoost) permite verificar se o ganho de desempenho compensa a perda de transparência, questão central em um setor regulado. No Brasil, a Lei Geral de Proteção de Dados (LGPD) assegura ao titular o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado (art. 20) e proíbe o tratamento para fins discriminatórios ilícitos ou abusivos (art. 6º, IX) [Brasil 2018]. Por isso, a explicabilidade (via SHAP) e a avaliação de equidade foram tratadas como requisitos do projeto, e não como acessórios.

1.3. Motivação

A inadimplência encarece o crédito para todos, pois o risco esperado é incorporado às taxas de juros, e o acesso ao crédito no Brasil ainda é desigual. Um modelo mais preciso e transparente pode apoiar decisões mais consistentes. O projeto está alinhado ao **ODS 8 – Trabalho Decente e Crescimento Econômico**, em particular à meta 8.10, que trata da ampliação do acesso a serviços bancários e financeiros, e ao **ODS 10 – Redução das Desigualdades**, metas 10.2 e 10.3, que tratam da inclusão econômica independentemente de idade e sexo e da redução de desigualdades de resultado. Conforme apontado na avaliação da proposta, esses benefícios não são consequência automática do uso de IA: um modelo pode reproduzir ou ampliar desigualdades presentes nos dados históricos. Por isso, este trabalho **mede** tanto o desempenho quanto as diferenças de erro entre grupos de sexo e idade, e discute o compromisso entre custo e inclusão.

1.4. Objetivo

O objetivo geral é desenvolver e comparar modelos de aprendizado de máquina supervisionado para classificar solicitantes de crédito como bons ou maus pagadores, construindo uma solução de apoio à decisão que seja precisa, calibrada, explicável e avaliada quanto à equidade. A variável-alvo é a coluna `Risk`, convertida para 1 (mau pagador) e 0 (bom pagador). Os objetivos específicos são:

- comparar Regressão Logística, Random Forest e XGBoost, com peso de classe e com SMOTENC para o desbalanceamento, ajustados por validação cruzada estratificada;
- escolher o limiar de decisão pela matriz de custo da base (custo 5 para aprovar um mau pagador e 1 para negar um bom pagador) e avaliar a calibração das probabilidades;
- atingir metas quantitativas definidas antes do treino (Seção 3.8): PR-AUC $\geq 0{,}50$, recall do mau pagador $\geq 0{,}70$, F1 $\geq 0{,}55$, custo médio $\leq 0{,}60$ por cliente, Brier $< 0{,}21$, ECE $\leq 0{,}05$ e diferenças de TPR e FPR entre grupos de no máximo 0,10;
- explicar o modelo com SHAP, avaliar a equidade entre sexos e faixas etárias com intervalos de confiança e testar medidas de mitigação;
- disponibilizar um protótipo de apoio à decisão que exiba a probabilidade, a recomendação e sua explicação.

1.5. Contribuições alcançadas

- **Formalização do problema:** inadimplência formulada como classificação binária com custo assimétrico, metas quantitativas e critérios de equidade explícitos.
- **Dados:** confirmação, registro a registro, da correspondência entre a versão simplificada e o dicionário original do UCI, o que corrigiu a interpretação dos ausentes em poupança e a codificação da conta corrente.
- **Protocolo experimental:** validação cruzada estratificada 5×2, pré-processamento e SMOTENC dentro de cada partição, limiar escolhido fora da amostra de teste e intervalos de confiança por *bootstrap*.
- **Avaliação:** os seis modelos superaram as referências triviais, mas a diferença entre eles ficou dentro da incerteza; no teste, a Regressão Logística igualou ou superou os modelos mais complexos.
- **Explicabilidade:** identificação da conta corrente, do prazo e da poupança como principais fatores, com explicações locais para cada cliente.
- **Equidade:** ausência de diferença relevante entre sexos e evidência de maior negativa indevida para clientes de até 25 anos, que persiste sem os atributos sensíveis; o modelo selecionado foi o de menor disparidade entre os três algoritmos, e o pós-processamento por faixa etária foi testado e teve seu custo quantificado.
- **Custo e inclusão:** quantificação de quanto a razão de custos adotada determina a negativa indevida de bons pagadores.
- **Aplicação e reprodutibilidade:** protótipo web com revisão humana obrigatória para casos limítrofes, e código, dados, modelo e resultados públicos no GitHub.

2. Fundamentação Teórica

2.1. Aprendizado supervisionado e classificação binária

No aprendizado supervisionado, um modelo aprende uma função que associa um vetor de atributos x a um rótulo y a partir de exemplos previamente rotulados, com o objetivo de generalizar para exemplos não vistos. Na concessão de crédito, o problema é formulado como classificação binária: $y = 1$ indica um cliente classificado como mau pagador e $y = 0$, um bom pagador. Os modelos aqui utilizados estimam a probabilidade $P(y = 1 \mid x)$, que é convertida em decisão por meio de um limiar t: o crédito é recomendado para negativa quando a probabilidade estimada é maior ou igual a t. A escolha de t não é um detalhe técnico, pois determina a proporção entre os dois tipos de erro e, portanto, o custo da decisão.

2.2. Regressão Logística

A Regressão Logística modela o logaritmo da razão de chances como uma combinação linear dos atributos, $\log[p/(1 - p)] = \beta_0 + \beta^T x$, e obtém a probabilidade pela função sigmoide. Os coeficientes são estimados por máxima verossimilhança com penalização (L2, que reduz a magnitude dos coeficientes, ou L1, que pode zerá-los e funcionar como seleção de atributos), controlada pelo hiperparâmetro C (inverso da força de regularização). Cada coeficiente tem interpretação direta como variação no log da chance de inadimplência, o que explica o uso histórico desse modelo em *credit scoring* e sua adoção como referência interpretável neste trabalho. Sua limitação é assumir relação linear e aditiva no espaço do log da chance, sem capturar interações não especificadas.

2.3. Random Forest

O Random Forest [Breiman 2001] é um conjunto de árvores de decisão treinadas em amostras *bootstrap* da base (*bagging*), em que cada divisão de nó considera apenas um subconjunto aleatório de atributos. A combinação dessas duas fontes de aleatoriedade reduz a correlação entre as árvores e, com isso, a variância do conjunto em relação a uma árvore isolada. A probabilidade prevista é a média das proporções de classe nas folhas das árvores. Os hiperparâmetros principais são a profundidade máxima, o número mínimo de exemplos por folha e a fração de atributos avaliada em cada divisão. O modelo captura não linearidades e interações automaticamente, mas não oferece uma equação interpretável, o que motiva o uso de técnicas de explicabilidade.

2.4. XGBoost

O XGBoost [Chen e Guestrin 2016] implementa *gradient boosting* de árvores: as árvores são adicionadas sequencialmente e cada nova árvore é ajustada para corrigir os erros do conjunto atual, seguindo o gradiente da função de perda (aqui, a perda logística). O algoritmo usa uma aproximação de segunda ordem da perda e uma função objetivo regularizada, que penaliza o número de folhas e a norma dos pesos das folhas. Somam-se a isso a taxa de aprendizado (*shrinkage*), que reduz a contribuição de cada árvore, e a subamostragem de exemplos e de atributos. Esses mecanismos tornam o XGBoost um dos métodos mais competitivos em dados tabulares, mas também mais sensível ao ajuste de hiperparâmetros, especialmente em bases pequenas como a deste estudo, nas quais o risco de sobreajuste é maior.

2.5. Desbalanceamento de classes

Quando uma classe é minoritária (aqui, 30% de maus pagadores), modelos tendem a favorecer a classe majoritária. Duas estratégias foram comparadas. A primeira é o **peso de classe**, que multiplica a contribuição dos exemplos minoritários na função de perda, sem alterar os dados. A segunda é a sobreamostragem sintética. O SMOTE [Chawla et al. 2002] cria exemplos da classe minoritária por interpolação entre um exemplo e seus vizinhos mais próximos; entretanto, aplicado a atributos categóricos codificados em *one-hot*, ele gera valores intermediários sem significado (por exemplo, 0,4 de "moradia própria"). Por isso, utilizou-se o **SMOTENC**, variante proposta no mesmo trabalho para dados mistos, que interpola apenas os atributos numéricos e atribui a cada atributo categórico a categoria mais frequente entre os vizinhos. Em ambos os casos, o balanceamento deve ocorrer somente nos dados de treino de cada partição, para que a avaliação reflita a distribuição real.

2.6. Métricas de avaliação, custo e calibração

Em bases desbalanceadas, a acurácia é enganosa: um modelo que aprova todos os clientes acerta 70% dos casos sem identificar nenhum mau pagador. Por isso, utilizaram-se métricas focadas na classe de interesse. O **recall** (ou TPR) é a fração de maus pagadores identificados; a **precisão** é a fração de clientes negados que de fato seriam maus pagadores; o **F1-score** é a média harmônica entre ambas. A **PR-AUC** (precisão média) resume a curva precisão-recall em todos os limiares e é mais informativa que a ROC-AUC em classes desbalanceadas [Saito e Rehmsmeier 2015]; seu valor de referência para um classificador aleatório é a prevalência (0,30). A **taxa de falsos positivos** (FPR), neste contexto, é a fração de bons pagadores negados indevidamente.

Os erros têm custos diferentes. A documentação original da base define uma matriz de custo em que aprovar um mau pagador (falso negativo) custa 5 e negar um bom pagador (falso positivo) custa 1 [Hofmann 1994]. O **custo médio por cliente** é $(5 \cdot FN + 1 \cdot FP)/n$. Se as probabilidades forem calibradas, o limiar que minimiza esse custo é $1/(1 + 5) \approx 0{,}167$.

Um modelo é **calibrado** quando, entre os clientes aos quais atribui probabilidade *p*, a fração de maus pagadores é aproximadamente *p*. A calibração foi medida pelo **escore de Brier** [Brier 1950], erro quadrático médio entre probabilidade prevista e resultado, e pelo **ECE** (*expected calibration error*), média ponderada das diferenças entre probabilidade prevista e frequência observada em faixas de probabilidade. Técnicas de balanceamento distorcem as probabilidades, e modelos como o Random Forest tendem a produzir probabilidades comprimidas [Niculescu-Mizil e Caruana 2005]; a calibração de Platt [Platt 1999], que ajusta uma sigmoide sobre o escore do modelo, corrige esse efeito sem alterar a ordenação dos clientes.

2.7. Inteligência Artificial Explicável (XAI) e SHAP

O SHAP (*SHapley Additive exPlanations*) [Lundberg e Lee 2017] atribui a cada atributo uma contribuição para a previsão de cada cliente, com base nos valores de Shapley da teoria dos jogos cooperativos: a contribuição de um atributo é sua contribuição marginal média sobre todas as combinações possíveis dos demais atributos. As contribuições somam exatamente a diferença entre a previsão do cliente e a previsão média (propriedade de aditividade), o que permite tanto explicações locais (por que um cliente específico foi classificado como alto risco) quanto globais (média dos valores absolutos sobre todos os clientes). Para modelos de árvores, o algoritmo TreeSHAP calcula esses valores de forma exata e eficiente [Lundberg et al. 2020]. Explicações, contudo, descrevem o comportamento do modelo, não a causalidade no mundo real, e não garantem que o modelo seja justo.

2.8. Equidade algorítmica

Equidade algorítmica trata de diferenças sistemáticas no comportamento de um modelo entre grupos definidos por atributos sensíveis, como sexo e idade. Este trabalho adota critérios baseados em **taxas de erro**: a **igualdade de oportunidade** [Hardt et al. 2016] exige taxas de verdadeiros positivos semelhantes entre grupos, e as **chances equalizadas** exigem, adicionalmente, taxas de falsos positivos semelhantes. No crédito, a diferença de FPR é especialmente relevante, pois corresponde a bons pagadores de um grupo sendo negados indevidamente com mais frequência. Diferenças na proporção real de maus pagadores entre grupos não comprovam, por si sós, discriminação do modelo; ao mesmo tempo, quando essas proporções diferem, não é possível satisfazer simultaneamente calibração por grupo e igualdade das taxas de erro [Kleinberg et al. 2017]. Por isso, os critérios precisam ser escolhidos explicitamente e medidos com sua incerteza amostral.

2.9. Trabalhos relacionados

Lessmann et al. (2015) compararam 41 classificadores em oito bases de crédito, incluindo a base alemã utilizada aqui, com métricas de desempenho variadas. Os conjuntos heterogêneos de modelos e o Random Forest obtiveram os melhores desempenhos médios, mas a Regressão Logística permaneceu uma referência competitiva, e os autores alertam que ganhos relatados em estudos com uma única base e poucas métricas tendem a não se generalizar. O trabalho é uma referência metodológica pela comparação sistemática, mas avalia apenas desempenho preditivo, sem tratar explicabilidade, calibração para decisão ou equidade [Lessmann et al. 2015].

Bussmann et al. (2021) aplicaram XGBoost com valores de Shapley a dados de cerca de 15 mil pequenas e médias empresas europeias e agruparam os clientes pela semelhança de suas explicações, mostrando que o modelo supera a Regressão Logística e que as explicações revelam perfis de risco distintos. A proposta demonstra o valor do SHAP em crédito, mas trata de crédito empresarial e não avalia efeitos sobre grupos de pessoas [Bussmann et al. 2021].

Gramegna e Giudici (2021) compararam SHAP e LIME em um modelo XGBoost de probabilidade de inadimplência treinado com cerca de 139 mil pequenas e médias

empresas italianas e concluíram que as explicações do SHAP têm maior poder discriminativo para separar bons e maus pagadores (AUC de 0,864 contra 0,839), o que sustenta a escolha do SHAP neste trabalho. De Lange et al. (2022) treinaram um LightGBM com explicações SHAP em dados de empréstimos pessoais sem garantia de um banco norueguês; o modelo superou claramente a Regressão Logística usada pelo banco, e o SHAP permitiu identificar os fatores que conduzem as previsões, argumento favorável à adoção desses modelos sob exigências de transparência. Ambos os estudos tratam a explicabilidade como requisito, mas não a confrontam com medidas de equidade.

Kozodoi et al. (2022) avaliaram critérios de equidade e técnicas de mitigação (pré-processamento, ajuste durante o treino e pós-processamento) em sete bases de crédito e analisaram o impacto da equidade sobre o lucro. Os autores argumentam que critérios baseados em taxas de erro, como a separação (chances equalizadas), são adequados ao crédito, e mostram que é possível reduzir disparidades com perda moderada de lucro: reduzir a diferença de separação para menos de 0,2 custou, em média, cerca de 5% do lucro, enquanto eliminá-la exigiria sacrificar mais de 35%. É o trabalho mais próximo da preocupação deste projeto, porém não combina a avaliação de equidade com explicações locais nem com estimativas de incerteza para bases pequenas [Kozodoi et al. 2022].

A Tabela 1 resume a comparação. O presente trabalho não propõe um algoritmo novo; sua contribuição está em reunir, em um mesmo protocolo reprodutível e sem vazamento de dados, a comparação de modelos, a decisão baseada em custo, a calibração, a explicação com SHAP e a avaliação de equidade com intervalos de confiança, sobre uma base pequena na qual a incerteza amostral precisa ser explicitada.

Tabela 1. Comparação entre trabalhos relacionados e o presente trabalho

Trabalho	Dados	Modelos	XAI	Custo/ limiar	Calibração	Equidade
Lessmann et al. (2015)	8 bases de crédito	41 classificadores	Não	Parcial	Não	Não
Bussmann et al. (2021)	~15 mil PMEs	LR, XGBoost	SHAP	Não	Não	Não
Gramegna e Giudici (2021)	~139 mil PMEs	XGBoost	SHAP x LIME	Não	Não	Não
de Lange et al. (2022)	crédito pessoal (banco norueguês)	LightGBM	SHAP	Não	Não	Não
Kozodoi et al. (2022)	7 bases de crédito	vários + mitigação	Não	Lucro	Não	Sim
Este trabalho	German Credit (1.000)	LR, RF, XGBoost	SHAP	Matriz 5:1	Brier, ECE, Platt	Sim, com IC 95%

3. Metodologia

3.1. Visão geral da abordagem

O trabalho seguiu as etapas: (1) caracterização e confirmação documental dos dados; (2) análise exploratória (realizada na N1 e revisada); (3) preparação dos dados dentro de *pipelines*; (4) treino e ajuste de hiperparâmetros de três algoritmos com duas estratégias de balanceamento, por validação cruzada; (5) seleção do modelo e escolha do limiar de decisão pelo custo; (6) calibração; (7) avaliação única no conjunto de teste, com intervalos de confiança; (8) explicação com SHAP; (9) avaliação de equidade e teste de mitigação; (10) análise de sensibilidade da redução de atributos; e (11) implementação de um protótipo de apoio à decisão. A implementação utilizou Python com scikit-learn

[Pedregosa et al. 2011], imbalanced-learn [Lemaître et al. 2017], XGBoost e SHAP; todo o código está nos notebooks do repositório (Seção 4.3).

3.2. Dataset: fonte, conteúdo e confirmação do dicionário

A base é o **Statlog (German Credit Data)** [Hofmann 1994], do UCI Machine Learning Repository (licença CC BY 4.0), com 1.000 solicitantes de crédito de um banco alemão, dos quais 700 classificados como bons pagadores e 300 como maus pagadores. Utilizou-se a versão simplificada com nove preditores e a coluna-alvo `Risk`, distribuída no Kaggle [Kaggle 2018]. Como a versão simplificada não traz dicionário próprio, ela foi cruzada registro a registro com o arquivo original do UCI (20 atributos codificados): idade, valor, prazo e rótulo coincidem nos 1.000 registros, e cada categoria da versão simplificada corresponde a exatamente um código (ou uma união de códigos) do dicionário original. A Tabela 2 lista os nove preditores e sua origem.

Tabela 2. Preditores da versão simplificada e correspondência com o dicionário original do UCI

Preditor	Atributo UCI	Tipo	Categorias / faixa
Age	A13 – idade	numérico	19 a 75 anos
Sex	A9 – estado civil e sexo	nominal	female = A92; male = A91, A93, A94
Job	A17 – qualificação	ordinal (0–3)	não qualificado não residente a altamente qualificado
Housing	A15 – moradia	nominal	própria, alugada, cedida
Saving accounts	A6 – poupança	nominal	< 100; 100–500; 500–1.000; ≥ 1.000 DM; ausente = A65
Checking account	A1 – conta corrente	nominal	< 0; 0–200; ≥ 200 DM; ausente = A14
Credit amount	A5 – valor	numérico	250 a 18.424 DM
Duration	A2 – prazo	numérico	4 a 72 meses
Purpose	A4 – finalidade	nominal	8 categorias (car = A40 + A41)

O cruzamento resolveu a questão levantada na N1 sobre o significado dos ausentes. Em `Checking account`, os 394 ausentes correspondem ao código A14, "não possui conta corrente", o que confirma a interpretação adotada. Em `Saving accounts`, porém, os 183 ausentes correspondem ao código A65, que o dicionário define como "desconhecida ou sem poupança"; portanto, a interpretação "sem conta" da N1 foi corrigida para uma categoria própria, "desconhecida ou sem poupança". O cruzamento revelou ainda que a categoria `little` de conta corrente significa saldo **negativo**, e não saldo pequeno.

A redução de 20 para 9 atributos mantém variáveis com nomes legíveis, o que facilita a interpretação das explicações e a demonstração no protótipo, e preserva sexo e idade, necessários à avaliação de equidade. Em contrapartida, descarta atributos relevantes, como o histórico de crédito. Como a redução tem custo, ele foi medido (Seção 4.2.6). Registra-se também que o atributo sexo é derivado de A9, que mistura sexo e estado civil, e que não há mulheres solteiras na base.

3.3. Análise exploratória (síntese)

A análise exploratória da N1 mostrou desbalanceamento de 70% para 30%; taxa de mau pagador de 11,7% entre quem não possui conta corrente, contra 41,9% entre quem possui; taxas maiores entre mulheres (35,2% contra 27,7% dos homens) e entre clientes de 18 a 25 anos (42,1% contra 22,2% acima de 60 anos); e valores e prazos médios maiores entre maus pagadores (3.938 DM e 24,9 meses, contra 2.985 DM e 19,2 meses). Essas diferenças entre grupos referem-se aos rótulos e não ao modelo; sua relevância para a equidade foi avaliada pelas taxas de erro do modelo (Seção 3.7).

3.4. Preparação dos dados e prevenção de vazamento

Os ausentes foram substituídos pelas categorias explícitas descritas na Seção 3.2, operação determinística que não aprende parâmetros dos dados. As demais transformações foram encapsuladas em um *pipeline*: logaritmo do valor do crédito (distribuição assimétrica), padronização das variáveis numéricas, codificação *one-hot* das categóricas e, quando aplicável, SMOTENC. Como o *pipeline* é ajustado dentro de cada partição da validação cruzada, a codificação, a padronização e a reamostragem são aprendidas somente com os dados de treino da partição, e a parte de validação mantém a distribuição original. A codificação ordinal de conta corrente e poupança usada na N1, que colocava "sem conta" abaixo de "saldo negativo", foi substituída por *one-hot*.

3.5. Protocolo experimental, modelos e ajuste de hiperparâmetros

A base foi dividida em 70% para treino (700 clientes) e 30% para teste (300 clientes), de forma estratificada e com semente fixa. O teste foi usado uma única vez, ao final. No treino, cada combinação de algoritmo e balanceamento foi ajustada por busca aleatória de hiperparâmetros com **validação cruzada estratificada de 5 partições repetida 2 vezes** (10 ajustes por candidato), maximizando a PR-AUC média. A Tabela 3 apresenta os espaços de busca. O balanceamento foi feito por peso de classe (`class_weight` balanceado na Regressão Logística e no Random Forest; `scale_pos_weight` = 7/3 no XGBoost) ou por SMOTENC. O critério de seleção do modelo final, definido antes da avaliação no teste, foi a maior PR-AUC média na validação cruzada.

Tabela 3. Espaços de busca de hiperparâmetros (busca aleatória)

Modelo	Hiperparâmetros e valores	Candidatos
Regressão Logística	C ~ log-uniforme [10^{-3}, 10^{2}]; penalização L1 ou L2	30
Random Forest	200 árvores; profundidade {3, 4, 5, 6, 8, 10, sem limite}; mín. por folha {1, 2, 5, 10, 20}; atributos por divisão {√p, 0,3, 0,5}	15
XGBoost	árvores {100, 200, 300, 500}; profundidade {2–5}; taxa de aprendizado ~ log-uniforme [0,01; 0,2]; subamostragem {0,6; 0,8; 1}; atributos por árvore {0,5; 0,7; 1}; peso mín. do filho {1, 3, 5, 10}; λ ~ log-uniforme [0,1; 10]	25

3.6. Custo dos erros, limiar de decisão e calibração

Com a matriz de custo da base (falso negativo = 5; falso positivo = 1), o limiar de decisão foi escolhido como o valor, em uma grade de 0,05 a 0,95, que minimiza o custo médio por cliente nas **predições fora da dobra** do conjunto de treino (validação cruzada de 5 partições, média de 3 repetições). Assim, o limiar não é ajustado com dados de teste. O modelo selecionado foi então calibrado pelo método de Platt, com validação cruzada interna de 5 partições, e o limiar foi recalculado sobre as probabilidades calibradas. Os critérios de calibração foram o escore de Brier, que deve ser inferior ao de prever sempre a prevalência (0,21), e o ECE, que deve ser no máximo 0,05.

3.7. Critérios de equidade e tratamento da incerteza

A equidade foi avaliada para sexo (feminino comparado com masculino) e faixa etária (até 25 anos comparado com 26 anos ou mais), pelas diferenças de TPR (recall de maus pagadores; igualdade de oportunidade), de FPR (negativa indevida de bons pagadores) e de taxa de aprovação. O critério adotado foi $|\Delta TPR| \leq 0{,}10$ e $|\Delta FPR| \leq 0{,}10$. Como os grupos são pequenos (no teste há cerca de 90 mulheres e 60 clientes de até 25 anos), todas as diferenças são acompanhadas de intervalos de confiança de 95% por *bootstrap* [Efron e

Tibshirani 1993], com 2.000 reamostragens. Para reduzir a incerteza, a avaliação foi repetida sobre as predições fora da dobra dos 1.000 clientes, obtidas pela validação cruzada do procedimento completo (modelo, calibração e o mesmo limiar). Uma diferença é considerada evidência de disparidade quando o intervalo exclui zero; quando o intervalo inclui zero mas ultrapassa ±0,10, o resultado é considerado inconclusivo.

3.8. Resultados esperados e metas quantitativas

Para substituir objetivos qualitativos por critérios verificáveis, foram definidas, antes do treino, as metas da Tabela 4, comparadas a referências simples: aprovar todos os clientes (custo de 1,50 por cliente) ou negar todos (custo de 0,70 por cliente e F1 de 0,46). A expectativa inicial era de que o Random Forest ou o XGBoost superassem a Regressão Logística, ao custo de menor interpretabilidade.

Tabela 4. Metas quantitativas definidas antes do treino

Meta	Critério (conjunto de teste)	Referência
M1	PR-AUC ≥ 0,50	aleatório = 0,30
M2	Recall do mau pagador ≥ 0,70	—
M3	F1 do mau pagador ≥ 0,55	negar todos = 0,46
M4	Custo médio por cliente ≤ 0,60	negar todos = 0,70; aprovar todos = 1,50
M5	Brier < 0,21 e ECE ≤ 0,05	prever a prevalência = 0,21
M6	|ΔTPR| e |ΔFPR| ≤ 0,10 entre grupos	avaliado com IC 95%

4. Resultados

4.1. Aspectos éticos e responsabilidade no uso da IA

Natureza dos dados e base legal. A base utilizada é pública, anonimizada e licenciada sob CC BY 4.0, e o estudo não envolveu contato com participantes, o que dispensa submissão a comitê de ética em pesquisa. Optou-se deliberadamente por não utilizar dados da instituição em que o autor trabalha: isso exigiria autorização formal do controlador, base legal, governança institucional e avaliação prévia dos riscos à privacidade. Ainda assim, os atributos (idade, sexo, situação financeira) são dados pessoais e sustentariam decisões de alto impacto em um sistema real; por isso, a solução foi desenhada considerando os princípios da LGPD [Brasil 2018]: finalidade (uso exclusivo para avaliação de risco), minimização (nove atributos, sem identificadores), transparência (explicação de cada recomendação) e o direito do titular à revisão de decisões tomadas unicamente com base em tratamento automatizado (art. 20).

Explicabilidade não é equidade. O SHAP mostra como o modelo decide, mas um modelo perfeitamente explicável pode tratar grupos de forma desigual. Por isso, desempenho e equidade foram avaliados separadamente, com critérios definidos antes dos resultados (meta M6) e com intervalos de confiança, de modo a distinguir diferenças reais de flutuações amostrais em grupos pequenos. Também se evitou interpretar a diferença na proporção real de maus pagadores entre sexos ou faixas etárias como prova de discriminação do modelo: essa diferença está nos rótulos históricos, que podem, eles próprios, refletir decisões passadas enviesadas.

Medidas concretas adotadas. (i) Avaliação de equidade por taxas de erro (TPR e FPR) entre sexos e faixas etárias, nas predições do teste e nas predições fora da dobra da base completa; (ii) teste empírico de mitigação por remoção dos atributos sensíveis, com análise do efeito sobre desempenho e disparidades, reconhecendo o risco de *proxies*; (iii) no protótipo, a saída é uma **recomendação**, e não uma decisão: casos próximos ao limiar (±0,05) são encaminhados obrigatoriamente para análise humana, e qualquer

recomendação de negativa é apresentada como sujeita a revisão; (iv) alerta automático quando sexo ou idade aparecem entre os três fatores de maior peso de uma explicação individual; (v) documentação pública do código, dos dados, das métricas por grupo e das limitações. Em um uso real, recomenda-se ainda monitoramento periódico das taxas de erro por grupo, revalidação do modelo com dados locais e avaliação jurídica sobre o uso de idade e sexo como atributos de decisão.

Limites de aplicação ao contexto brasileiro. A base descreve clientes de um banco alemão, com valores em marcos alemães, em um período anterior a 1994, e contém apenas 1.000 registros. A população, os produtos de crédito, a renda, a inflação, a regulação e as fontes de informação disponíveis no Brasil atual (por exemplo, o Cadastro Positivo [Brasil 2019] e o histórico de pagamentos em birôs de crédito) são diferentes. O rótulo "mau pagador" foi atribuído pela instituição de origem sem definição documentada de horizonte de atraso. Portanto, os resultados não devem ser transpostos para decisões reais no Brasil: o trabalho demonstra um **método** de desenvolvimento e avaliação responsável, que precisaria ser reaplicado com dados locais, rótulo definido explicitamente (por exemplo, atraso superior a 90 dias em 12 meses) e validação temporal.

Uso de IA generativa. Ferramentas de IA generativa (Claude, da Anthropic) foram utilizadas como apoio no desenvolvimento deste trabalho, conforme declarado na entrega à disciplina. O autor revisou o código, os resultados e o texto e responde integralmente pelo conteúdo.

4.2. Detalhamento dos resultados

4.2.1. Validação cruzada e seleção do modelo

A Tabela 5 mostra o desempenho de cada configuração na validação cruzada 5×2 do treino, com os melhores hiperparâmetros encontrados. As seis configurações ficaram próximas: a PR-AUC média variou de 0,560 a 0,586, e as diferenças entre elas são menores que o desvio-padrão entre partições (cerca de 0,05 a 0,07). O peso de classe foi ligeiramente superior ao SMOTENC nos três algoritmos. Pelo critério definido previamente, o modelo selecionado foi o **Random Forest com peso de classe** (PR-AUC de 0,586), cujos melhores hiperparâmetros indicaram árvores rasas (profundidade 3, 50% dos atributos por divisão). O XGBoost também convergiu para árvores muito rasas (profundidade 2) e taxa de aprendizado baixa (0,014), e a Regressão Logística, para regularização forte (L2, $C = 0{,}09$). A preferência dos três algoritmos por modelos simples é coerente com uma base de apenas 700 exemplos de treino e com a disponibilidade de poucos atributos informativos.

Tabela 5. Validação cruzada estratificada 5×2 no treino (melhor candidato de cada configuração)

Modelo	Balanceamento	PR-AUC (média ± DP)	ROC-AUC	Brier
Regressão Logística	peso de classe	0,570 ± 0,059	0,744	0,204
Regressão Logística	SMOTENC	0,562 ± 0,047	0,734	0,206
Random Forest	peso de classe	0,586 ± 0,055	0,758	0,200
Random Forest	SMOTENC	0,574 ± 0,047	0,746	0,200
XGBoost	peso de classe	0,571 ± 0,069	0,755	0,201
XGBoost	SMOTENC	0,560 ± 0,054	0,744	0,197

4.2.2. Desempenho no conjunto de teste

A Tabela 6 apresenta todas as configurações no teste, cada uma com o limiar de custo escolhido nas predições fora da dobra do seu treino. Todas superaram as referências

simples: aprovar todos custa 1,50 por cliente e negar todos custa 0,70 (F1 de 0,46). O resultado mais importante, porém, contraria a expectativa inicial e a própria seleção: no teste, a **Regressão Logística com peso de classe obteve a maior PR-AUC (0,635) e o menor custo (0,550 por cliente)**, enquanto o Random Forest selecionado obteve PR-AUC de 0,556. Na comparação pareada por *bootstrap* (mesmas reamostragens para os dois modelos), a diferença de PR-AUC entre o modelo final e a Regressão Logística foi de −0,068 (IC 95%: −0,131 a −0,007), mas a diferença de custo por cliente, +0,032 (IC 95%: −0,063 a +0,117), não é estatisticamente distinguível de zero. Ou seja, a vantagem do Random Forest na validação cruzada estava dentro da variabilidade amostral e não se confirmou; na decisão efetivamente tomada (custo), os modelos são equivalentes.

Tabela 6. Desempenho no teste (300 clientes) com o limiar de custo de cada configuração

Modelo	Balanc.	Limiar	PR-AUC	ROC-AUC	F1	Recall	FPR	Custo
Regressão Logística	peso	0,415	0,635	0,766	0,588	0,833	0,429	0,550
Regressão Logística	SMOTENC	0,285	0,639	0,759	0,558	0,878	0,543	0,563
Random Forest	peso	0,360	0,556	0,756	0,554	0,856	0,529	0,587
Random Forest	SMOTENC	0,300	0,556	0,740	0,554	0,856	0,529	0,587
XGBoost	peso	0,445	0,596	0,766	0,577	0,789	0,405	0,600
XGBoost	SMOTENC	0,320	0,559	0,748	0,561	0,844	0,500	0,583
Aprovar todos	—	—	—	—	0,000	0,000	0,000	1,500
Negar todos	—	—	—	—	0,462	1,000	1,000	0,700

A calibração de Platt reduziu o Brier do modelo final de 0,200 para 0,174 e o ECE de 0,153 para 0,059, praticamente sem alterar a ordenação dos clientes (PR-AUC de 0,556 para 0,564). Com as probabilidades calibradas, o limiar de custo escolhido no treino foi 0,190, próximo do valor teórico de 0,167, o que indica que a calibração funcionou. A Tabela 7 apresenta as métricas finais com intervalos de confiança, e a Figura 1 mostra as curvas precisão-recall, a matriz de confusão e a curva de calibração.

Tabela 7. Modelo final (Random Forest + peso de classe + calibração de Platt, limiar 0,190) no teste

Métrica	Estimativa	IC 95% (bootstrap)
PR-AUC	0,564	0,466 – 0,674
ROC-AUC	0,763	0,704 – 0,819
F1 (mau pagador)	0,556	0,479 – 0,625
Recall (mau pagador)	0,856	0,776 – 0,923
Brier	0,174	0,153 – 0,195
Custo médio por cliente	0,583	0,470 – 0,713

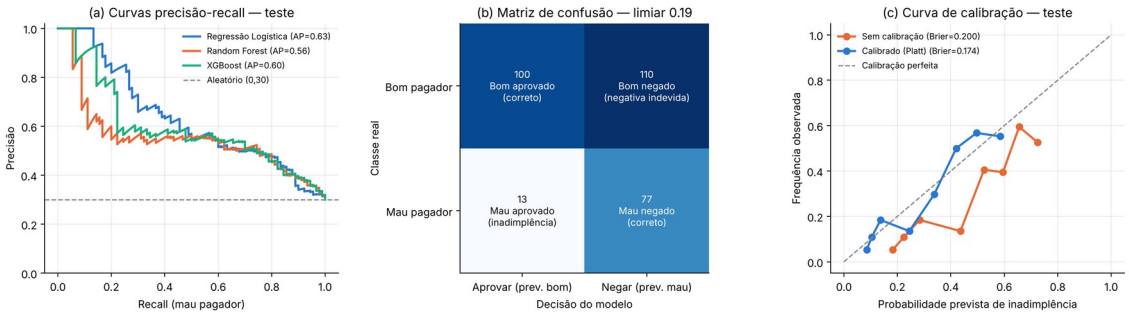


Figura 1. (a) Curvas precisão-recall no teste; (b) matriz de confusão do modelo final; (c) curva de calibração antes e depois da calibração de Platt

A matriz de confusão evidencia o efeito da matriz de custo 5:1: o modelo identificou 77 dos 90 maus pagadores (recall de 0,86), deixando passar 13, mas negou indevidamente 110 dos 210 bons pagadores (FPR de 0,52). Como aprovar um mau pagador custa cinco vezes mais, o limiar ótimo é baixo e o modelo nega muito.

4.2.3. Verificação das metas e o compromisso entre custo e inclusão

A Tabela 8 confronta os resultados com as metas definidas antes do treino. As metas M1 a M5a foram atingidas, embora M3 e M4 por margem pequena: o intervalo de confiança do custo (0,47 a 0,71) inclui o custo da política de negar todos (0,70), de modo que a vantagem econômica sobre essa referência trivial não é conclusiva com 300 clientes de teste. A meta de calibração M5b (ECE ≤ 0,05) não foi atingida por pouco (0,059), e a meta de equidade M6 não foi atingida para a faixa etária (Seção 4.2.5).

Tabela 8. Verificação das metas (conjunto de teste)

Meta	Critério	Resultado	Situação
M1	PR-AUC ≥ 0,50	0,564	Atingida
M2	Recall ≥ 0,70	0,856	Atingida
M3	F1 ≥ 0,55	0,556	Atingida (margem pequena)
M4	Custo ≤ 0,60 por cliente	0,583	Atingida (IC inclui 0,70)
M5	Brier < 0,21; ECE ≤ 0,05	0,174; 0,059	Brier sim; ECE não
M6	|ΔTPR|, |ΔFPR| ≤ 0,10	sexo: sim; idade: ΔFPR = 0,16	Não atingida (idade)

A Tabela 9 e a Figura 2 tornam explícito o compromisso entre custo e inclusão. A matriz 5:1 é uma escolha normativa da instituição de origem: quanto mais caro se considera aprovar um mau pagador, menor o limiar e mais bons pagadores são negados. Com a razão 5:1, o modelo aprova apenas 38% dos solicitantes e nega 52% dos bons pagadores; com a razão 2:1, o recall cai de 0,86 para 0,74, mas a negativa indevida cai de 0,52 para 0,31 e a aprovação sobe para 56%. Com custos iguais (1:1), a negativa indevida seria de apenas 0,12, porém dois terços dos maus pagadores seriam aprovados. Do ponto de vista dos ODS 8 e 10, a escolha da razão de custo é, portanto, tão determinante para a inclusão financeira quanto a escolha do algoritmo, e deve ser feita de forma transparente pela instituição.

Tabela 9. Efeito da razão de custo (limiar escolhido no treino; resultados no teste)

Razão FN:FP	Limiar	Recall (mau)	Negativa indevida (FPR)	Aprovação	Maus aprovados	Bons negados
1:1	0,490	0,333	0,119	0,817	60	25
2:1	0,335	0,744	0,310	0,560	23	65
3:1	0,315	0,767	0,329	0,540	21	69
5:1 (adotada)	0,190	0,856	0,524	0,377	13	110

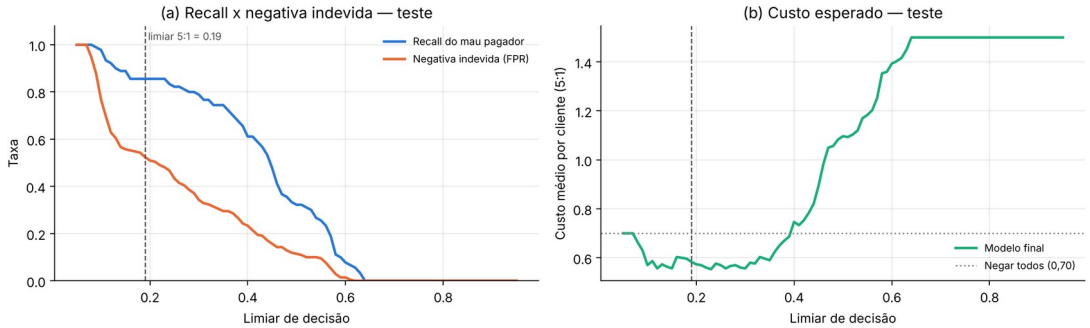


Figura 2. (a) Recall do mau pagador e negativa indevida em função do limiar; (b) custo médio por cliente com a matriz 5:1 (teste)

4.2.4. Explicabilidade com SHAP

A Figura 3 apresenta a importância global das variáveis (média dos valores SHAP absolutos) e a distribuição das contribuições por cliente. A situação da conta corrente é, com grande folga, o fator mais importante (0,155), mais de três vezes o segundo, o prazo (0,043), seguido da poupança (0,035) e do valor do crédito (0,019). O sentido das contribuições é coerente com a análise exploratória: **não possuir conta corrente reduz** o risco previsto, enquanto saldo negativo, prazos longos, valores altos e poupança baixa o aumentam. Os atributos sensíveis aparecem com baixa importância global: idade (0,010) e sexo (0,007) ocupam a sexta e a sétima posições. A Figura 4 mostra uma explicação local: para um mau pagador corretamente negado, a decisão foi conduzida principalmente pelo saldo negativo em conta corrente, pelo prazo de 45 meses e pelo valor elevado. Explicações desse tipo permitem que um analista confira a recomendação e que o cliente receba os principais motivos de uma negativa.



Figura 3. SHAP: (a) importância global por variável (atributos sensíveis em vermelho); (b) contribuições individuais das dez colunas mais importantes

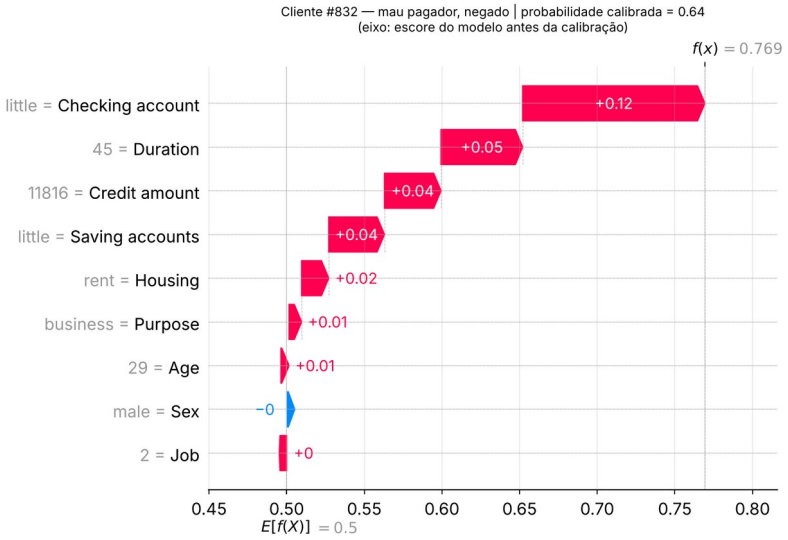


Figura 4. Explicação local (SHAP) de um mau pagador negado pelo modelo

A baixa importância de sexo e idade não significa ausência de efeito sobre esses grupos. Variáveis como moradia, poupança e prazo podem estar associadas a eles e funcionar como *proxies*, o que é examinado a seguir.

4.2.5. Equidade entre grupos e medidas de mitigação

A Tabela 10 apresenta as taxas por grupo nas predições fora da dobra dos 1.000 clientes, e a Figura 5 mostra as diferenças com intervalos de confiança nas duas bases de avaliação. Para **sexo**, as diferenças são pequenas: ΔTPR = +0,002 (IC 95%: −0,077 a +0,078) e ΔFPR = +0,026 (IC 95%: −0,056 a +0,109). Os intervalos incluem zero; o limite superior do ΔFPR ultrapassa 0,10 por margem mínima, de modo que a meta é considerada atendida na estimativa pontual, mas sem garantia estatística. Para **idade**, há disparidade: bons pagadores de até 25 anos foram negados indevidamente em 65,5% dos casos, contra 49,3% dos clientes com 26 anos ou mais, ΔFPR = +0,161 (IC 95%: +0,058 a +0,258), intervalo que exclui zero e ultrapassa o limite de 0,10. A taxa de aprovação dos jovens foi 58% da dos demais (IC 95%: 43% a 74%). No teste isolado, a diferença tem a mesma direção (+0,139), mas o intervalo (−0,040 a +0,307) é largo demais para ser conclusivo, o que reforça a necessidade de usar toda a base na avaliação de equidade.

Tabela 10. Taxas por grupo nas predições fora da dobra (n = 1.000; limiar 0,190)

Grupo	n	Taxa real de maus	Aprovação	TPR (recall)	FPR (negativa indevida)
Masculino	690	0,277	0,390	0,869	0,511
Feminino	310	0,352	0,345	0,872	0,537
26 anos ou mais	810	0,272	0,409	0,855	0,493
Até 25 anos	190	0,421	0,237	0,912	0,655

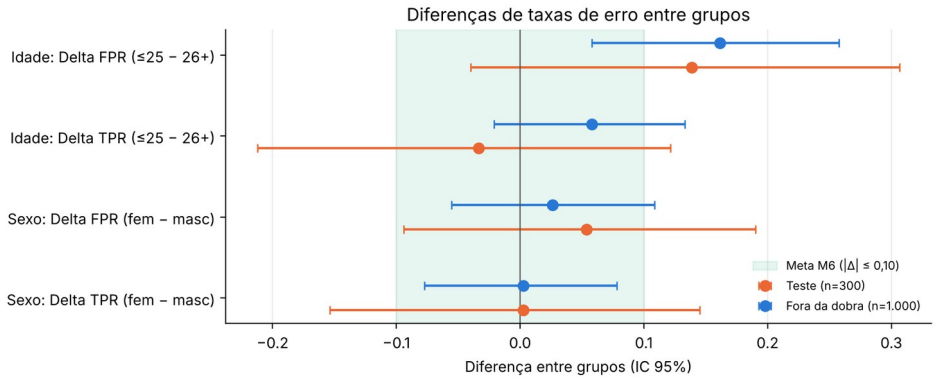


Figura 5. Diferenças de TPR e FPR entre grupos, com IC 95%, no teste e nas predições fora da dobra

A Tabela 11 mostra a medida de mitigação por remoção dos atributos sensíveis. Remover o sexo eliminou praticamente a diferença residual entre sexos (ΔFPR de 0,026 para 0,011), com efeito desprezível sobre o desempenho. Remover sexo e idade, porém, reduziu a disparidade etária apenas de 0,161 para 0,153: a diferença persiste porque é transmitida por outras variáveis associadas à idade, como moradia, poupança e prazo. Esse resultado demonstra empiricamente que "não usar o atributo sensível" não é suficiente para garantir equidade.

Tabela 11. Efeito da remoção dos atributos sensíveis (predições fora da dobra, n = 1.000)

Variante	PR-AUC	Recall	Custo	ΔFPR sexo	ΔTPR idade	ΔFPR idade
Completo (9 variáveis)	0,549	0,870	0,558	+0,026	+0,058	+0,161
Sem sexo	0,550	0,870	0,562	+0,011	+0,041	+0,155
Sem sexo e idade	0,556	0,867	0,568	+0,002	+0,028	+0,153

A disparidade etária não é exclusiva do modelo selecionado. A Tabela 12 repete a avaliação com a melhor configuração de cada algoritmo: a Regressão Logística e o XGBoost apresentam diferenças etárias ainda maiores (ΔFPR de +0,258 e +0,281, respectivamente), e a Regressão Logística também apresenta diferença entre sexos com intervalo que exclui zero (ΔFPR = +0,085). Entre os três, o Random Forest selecionado foi o que apresentou **menor disparidade**, com custo equivalente. Isso evidencia um segundo compromisso: o modelo de melhor ordenação no teste (Regressão Logística) não é o mais equitativo, e a escolha do modelo deveria considerar desempenho e equidade em conjunto.

Tabela 12. Equidade por algoritmo (predições fora da dobra, n = 1.000; IC 95% entre colchetes)

Modelo	Limiar	PR-AUC	Custo	ΔFPR idade	ΔTPR idade	ΔFPR sexo
Regressão Logística	0,235	0,565	0,561	+0,258 [+0,156; +0,357]	+0,095 [+0,008; +0,175]	+0,085 [+0,003; +0,166]
Random Forest (final)	0,190	0,549	0,558	+0,161 [+0,058; +0,258]	+0,058 [−0,021; +0,133]	+0,026 [−0,056; +0,109]
XGBoost	0,280	0,553	0,607	+0,281 [+0,184; +0,376]	+0,122 [+0,027; +0,212]	+0,065 [−0,015; +0,148]

Por fim, testou-se uma medida de pós-processamento: um limiar específico para clientes de até 25 anos, escolhido no treino para igualar a negativa indevida à do grupo de 26 anos ou mais (Tabela 13). O limiar dos jovens subiu de 0,190 para 0,360, e a diferença

de FPR no teste caiu de +0,139 para −0,028. Em contrapartida, a diferença de recall passou a ser desfavorável aos jovens (ΔTPR = −0,200; IC 95%: −0,399 a −0,011), o recall geral caiu de 0,856 para 0,800 e o custo subiu de 0,583 para 0,647 por cliente. O resultado ilustra, na prática, o limite teórico discutido na Seção 2.8: com taxas reais de inadimplência diferentes entre grupos, igualar um tipo de erro desequilibra o outro. Além disso, usar a idade explicitamente na decisão exige avaliação jurídica à luz do princípio da não discriminação da LGPD. Por essas razões, o pós-processamento não foi incorporado ao protótipo; a medida adotada foi a revisão humana dos casos limítrofes, somada ao monitoramento das taxas por grupo.

Tabela 13. Pós-processamento com limiar por faixa etária (teste; IC 95% entre colchetes)

Política	Recall (mau)	FPR geral	Custo	ΔFPR idade	ΔTPR idade
Limiar único (0,190)	0,856	0,524	0,583	+0,139 [−0,040; +0,307]	−0,033 [−0,212; +0,122]
Limiar por faixa (0,360 até 25 anos)	0,800	0,495	0,647	−0,028 [−0,212; +0,156]	−0,200 [−0,399; −0,011]

4.2.6. Custo da simplificação da base

Com os 20 atributos originais e o mesmo procedimento de ajuste, a PR-AUC no teste subiu de 0,556 para 0,623 e a ROC-AUC, de 0,756 para 0,795 (na validação cruzada, de 0,586 para 0,624). A versão simplificada, portanto, perde informação preditiva relevante, principalmente o histórico de crédito. A escolha foi mantida pelos motivos expostos na Seção 3.2, mas um sistema real deveria incluir esse tipo de informação, hoje disponível no Brasil por meio dos birôs de crédito e do Cadastro Positivo.

4.2.7. Protótipo de apoio à decisão

O modelo final foi incorporado a um protótipo web desenvolvido com Streamlit (Figura 6). O usuário informa os nove atributos do solicitante e recebe a probabilidade calibrada de inadimplência, a recomendação e as contribuições SHAP de cada variável. A recomendação segue três faixas: aprovar (probabilidade abaixo do limiar menos 0,05), encaminhar para análise humana (dentro de ±0,05 do limiar) e negar, sempre indicada como sujeita a revisão humana. O protótipo também alerta quando sexo ou idade estão entre os três fatores de maior peso e exibe o desempenho e as limitações do modelo.



Figura 6. Protótipo CredScore AI: avaliação de uma solicitante de 23 anos, com recomendação e explicação SHAP

4.3. Endereço do GitHub e do vídeo

Repositório público com o artigo, o dataset e sua descrição, os notebooks, o código-fonte do protótipo, o modelo treinado e as tabelas e figuras de resultados: https://github.com/DADAISKE/Projeto-IA

Vídeo de apresentação (até 5 minutos): **[INSERIR O LINK DO VÍDEO NO YOUTUBE]**

5. Conclusão

Este trabalho desenvolveu e avaliou o CredScore AI, uma solução de apoio à decisão de crédito ao consumidor baseada em aprendizado de máquina, com o objetivo de ser precisa, calibrada, explicável e avaliada quanto à equidade. A partir da base Statlog (German Credit Data), foram comparadas a Regressão Logística, o Random Forest e o XGBoost, com dois métodos de balanceamento, sob um protocolo que evita vazamento de dados, escolhe o limiar pelo custo dos erros e reporta a incerteza dos resultados.

O objetivo foi **alcançado em sua maior parte**. O modelo final (Random Forest com peso de classe e calibração de Platt) atingiu as metas de PR-AUC (0,564), recall do mau pagador (0,856), F1 (0,556), custo médio (0,583 por cliente) e escore de Brier (0,174). Duas metas não foram atingidas: o ECE ficou em 0,059, ligeiramente acima de 0,05, e a diferença de negativa indevida entre clientes de até 25 anos e os demais (+0,16) superou o limite de 0,10, com intervalo de confiança que exclui zero. Entre sexos, não se observou diferença relevante.

Os resultados permitem três conclusões principais. Primeiro, em uma base pequena e com poucos atributos, **modelos mais complexos não garantiram melhor desempenho**: as diferenças na validação cruzada ficaram dentro da variabilidade amostral, e no teste a Regressão Logística teve a melhor ordenação, em linha com a

observação de Lessmann et al. (2015) de que ganhos relatados em estudos isolados tendem a não se generalizar. Segundo, **desempenho e equidade precisam ser avaliados em conjunto**: o algoritmo de melhor ordenação no teste foi também o que apresentou maiores disparidades, e o modelo selecionado foi o de menor disparidade entre os três. Terceiro, **explicabilidade e remoção de atributos sensíveis não bastam**: o SHAP indicou baixa importância direta de idade e sexo, mas a disparidade etária persistiu sem esses atributos, transmitida por variáveis correlacionadas; e o pós-processamento por faixa etária, embora igualasse a negativa indevida, desequilibrou o recall e aumentou o custo. Somou-se a isso a constatação de que a matriz de custo 5:1 leva o modelo a negar mais da metade dos bons pagadores, o que mostra que a inclusão financeira depende de uma escolha explícita de custos, e não apenas da técnica.

As contribuições obtidas foram: a formalização do problema com metas quantitativas e critérios de equidade definidos antecipadamente; a confirmação documental do significado dos atributos, que corrigiu interpretações da etapa anterior; um protocolo experimental reprodutível; a demonstração quantitativa das vantagens e limitações de cada modelo; as explicações globais e locais com SHAP; a análise de equidade com incerteza e com medidas de mitigação testadas; e um protótipo funcional que exibe recomendação e explicação e encaminha casos limítrofes para revisão humana.

As principais limitações são o tamanho da base (300 clientes no teste, com intervalos de confiança largos), sua origem alemã e histórica, a ausência de definição documentada do evento de inadimplência e a perda de informação da versão simplificada, que reduziu a PR-AUC de 0,623 para 0,556 em relação à versão completa. Como trabalhos futuros, propõem-se: reaplicar o método a dados brasileiros recentes, com rótulo definido explicitamente e validação temporal; incluir informações de histórico de crédito; comparar técnicas de mitigação aplicadas durante o treino; e incorporar critérios de equidade à própria seleção do modelo, em vez de avaliá-los apenas depois.

Referências

Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). *Diário Oficial da União*, Brasília, DF.

Brasil (2019). Lei Complementar nº 166, de 8 de abril de 2019. Dispõe sobre os cadastros positivos de crédito. *Diário Oficial da União*, Brasília, DF.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3.

Bussmann, N., Giudici, P., Marinelli, D. e Papenbrock, J. (2021). Explainable machine learning in credit risk management. *Computational Economics*, 57(1):203–216.

Chawla, N. V., Bowyer, K. W., Hall, L. O. e Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.

Chen, T. e Guestrin, C. (2016). XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, p. 785–794.

de Lange, P. E., Melsom, B., Vennerød, C. B. e Westgaard, S. (2022). Explainable AI for credit assessment in banks. *Journal of Risk and Financial Management*, 15(12):556.

Efron, B. e Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.

Gramegna, A. e Giudici, P. (2021). SHAP and LIME: an evaluation of discriminative power in credit risk. *Frontiers in Artificial Intelligence*, 4:752558.

Hardt, M., Price, E. e Srebro, N. (2016). Equality of opportunity in supervised learning. In *Advances in Neural Information Processing Systems 29*, p. 3315–3323.

Hofmann, H. (1994). Statlog (German Credit Data). UCI Machine Learning Repository. https://doi.org/10.24432/C5NC77

Kaggle (2018). German Credit Risk – with target. Versão simplificada do Statlog (German Credit Data). https://www.kaggle.com/datasets/kabure/german-credit-data-with-risk

Kleinberg, J., Mullainathan, S. e Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. In *Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS)*, p. 43:1–43:23.

Kozodoi, N., Jacob, J. e Lessmann, S. (2022). Fairness in credit scoring: assessment, implementation and profit implications. *European Journal of Operational Research*, 297(3):1083–1094.

Lemaître, G., Nogueira, F. e Aridas, C. K. (2017). Imbalanced-learn: a Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17):1–5.

Lessmann, S., Baesens, B., Seow, H.-V. e Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: an update of research. *European Journal of Operational Research*, 247(1):124–136.

Lundberg, S. M. e Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, p. 4765–4774.

Lundberg, S. M., Erion, G., Chen, H. et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1):56–67.

Niculescu-Mizil, A. e Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, p. 625–632.

Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In Smola, A. et al. (eds.), *Advances in Large Margin Classifiers*, p. 61–74. MIT Press.

Saito, T. e Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3):e0118432.